Université Claude Bernard Lyon 1 2016–2017
Polytech Lyon - Département Informatique
4A

IA

TP2. Apprentissage par renforcement

Laëtitia Matignon

Vous devez rendre votre compte-rendu sous forme d'une archive dans le module spiral **IA-MDP**, zone de dépôt `CR TP`. L'archive sera nommée `TP2-nom1-nom2`. Le compte-rendu peut se faire en monôme ou binôme.

Votre archive contiendra les classes complétées et commentées suivantes :
- `QLearningAgent.java` du package `agent.rlagent`
- `StrategyGreedy.java` du package `agent.strategy`
- `EtatPacmanMDPClassic` du package `pacman.environnementRL`
- `QLApproxAgent` du package `agent.rlapproxagent`
- `FeatureFunctionIdentity` du package `agent.rlapproxagent`
- `FeatureFunctionPacman` du package `agent.rlapproxagent`

L'objectif du TP est d'implémenter et de tester dans différents environnements un algorithme d'apprentissage par renforcement : le Q-learning. Pour cela, reprenez le projet utilisé au TP1. **Vous devez récupérer le code `rlapproxagent.zip` sur Spiral, et copier le dossier contenu dans cette archive dans le code source de votre projet actuel (chemin `src/agent/.`) afin de mettre à jour le package `agent.rlapproxagent.`**

Vous trouverez aussi en annexe de cet énoncé de TP le diagramme de classes des éléments utilisés dans ce TP.

1 Agent Q-Learning tabulaire

On s'intéresse ici au Q-learning tabulaire, c'est-à-dire utilisant une matrice de Q-valeurs. Cette matrice notée Q est de dimension $|S| \times |A|$ avec des valeurs dans $\Re$.

$Q^\pi(s,a)$ évalue les récompenses espérées lorsque l'on effectue l'action a dans l'état s puis que l'on suit la politique π : $Q^\pi(s,a) = E\{\sum_{t=0}^{\infty} \gamma^t r_{t+1} | \pi, s_t = s, a_t = a\}$

La classe pour implémenter un agent apprenant avec le Q-learning est nommée `QLearningAgent`. Elle se trouve dans le package `agent.rlagent`. Elle hérite de la classe abstraite `RLAgent`, qui se charge de gérer le lancement des épisodes [1] et l'interaction de

1. Un épisode débute avec l'agent à son état initial et se termine lorsque l'agent atteint un état absorbant ou lorsque le nombre d'actions depuis l'état initial est supérieur au nombre d'actions maximum autorisées par épisode.

l'agent avec l'environnement à chaque action. En particulier, lorsqu'un agent réalise une action a, la fonction `endStep` de `QLearningAgent` est appelée avec les paramètres correspondant à l'interaction de l'agent avec l'environnement. Ces paramètres sont (s, a, s', r) avec s l'état dans lequel l'agent a réalisé l'action a, s' l'état d'arrivé et r la récompense reçue.

1.1 Agent avec exploration manuelle

Tout d'abord, l'agent sera contrôlé manuellement via les flèches du clavier.

Question 1 *Compléter la classe `QLearningAgent` pour que l'agent mette à jour sa table des Q-valeurs en fonction des actions réalisées au clavier.*

Quelques précisions par rapport à la question précédente :

— pour toute modification d'une Q-valeur, utilisez dans votre code la méthode `setQValeur` (méthode que vous devez compléter), la vue sera ainsi automatiquement notifiée et mise à jour.

Question 2 *Pour vérifier votre implémentation, testez votre agent en exécutant la classe `testQLAgentGridworld` du package `simuTP2`. Vous choisirez une stratégie d'exploration manuelle (vous déplacez vous-même l'agent dans le labyrinthe). Vérifier les différents éléments calculés (Q-valeurs, valeurs et politique) par votre agent. Le bouton ResetAgent permet de replacer l'agent à son état de départ.*

1.2 Agent avec stratégie d'exploration

La stratégie d'exploration utilisée par l'agent est implémentée dans la classe `StrategyGreedy` du package `agent.strategy`.

Question 3 *Complétez la classe `StrategyGreedy` de sorte à ce que l'agent utilise une stratégie d'exploration ϵ-greedy.*

Question 4 *Testez votre agent en exécutant la classe `testQLAgentGridworld` et en choisissant une stratégie greedy. Les valeurs obtenues après quelques centaines d'épisodes et $\epsilon = 0.1$ doivent être du même ordre que les valeurs calculées par votre agent value iteration du TP1.*

Quelques précisions par rapport à la question précédente :

— Dans l'interface graphique, lorsque vous lancez un seul épisode ($n = 1$), vous pouvez voir l'agent se déplacer dans l'environnement. Lorsque vous lancez plusieurs épisodes ($n > 1$), l'affichage de l'état courant de votre agent est désactivé. Le nombre de pas (ou nombre d'actions) par épisode s'affiche dans la console.

1.3 Nouvel environnement : le robot "*crawler*"

On considère maintenant un robot composé d'un bras en deux parties. La partie haute du bras possède 4 positions possibles, et la partie basse 6 positions. 4 actions sont

possibles correspondant au fait de monter ou descendre d'une position l'une des deux parties du bras.

Question 5 *Exécuter la classe* `testMoveCrawler` *pour contrôler manuellement le robot. La récompense reçue après chaque transition s'affiche dans la console. Quel comportement aura le robot s'il suit sa politique optimale ?*

Question 6 *Vérifier votre réponse à la question précédente en utilisant votre agent q-learning pour faire apprendre ce comportement au robot. Pour cela, exécutez la classe* `testQLAgentCrawler` *du package* `simuTP2`*.*

2 Maintenant Jouons à Pacman !

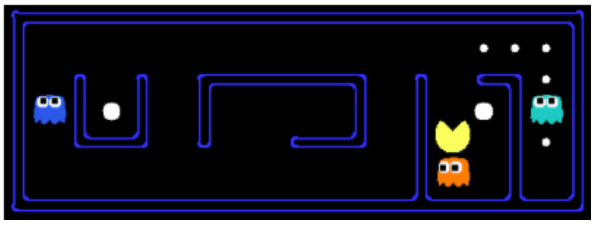

On souhaite maintenant avoir un agent qui apprend par renforcement à jouer au jeu de Pacman.

2.1 Jeu Pacman

Les règles du jeu Pacman utilisé dans ce TP sont définies telles que l'on a :

- un seul pacman,
- un ou plusieurs fantômes, qui se déplacent de façon aléatoire
- uniquement des pac-dots (pas de big-dots [2])
- la partie est gagnée si le pacman mange tous les dots
- la partie est perdue si le pacman est mangé par un fantôme (une seule vie pour le pacman)
- le score est calculé de la manière suivante à chaque itération [3] : manger un dot rapporte 10 points, gagner la partie rapport 500 points, perdre la partie rapporte -500 points. Le score est décrémenté de 2 à chaque itération.

Un état du jeu à chaque instant est défini dans la classe `pacman.elements.StateGamePacman`. Il contient la configuration du labyrinthe (position des murs, positions des fantômes et des pac-dots, ...), l'état du pacman et des fantômes, le nombre de dots mangé, le score, ...

Vous pouvez tester votre performance au jeu de Pacman (sans y passez le reste du TP ...) en exécutant la classe `PacmanGame` du package `simuProjetPacman`.

2. un big-dot mangé par un pacman entraine une invincibilité du pacman pendant quelques instants
3. Une itération du jeu consiste en un déplacement du pacman puis le déplacement des fantômes.

2.2 Q-Learning tabulaire pour le jeu Pacman : comment définir les états du MDP ?

Pour utiliser un agent apprenant par renforcement dans le jeu Pacman, il faut définir les **éléments du MDP** qui seront utilisés par l'agent apprenant par renforcement :

- l'ensemble des **actions** : l'agent pacman peut faire au plus[4] 4 actions à chaque itération (NORD,SUD,EST,OUEST).
- les actions d'un agent pacman sont déterministes, la stochasticité de l'environnement vient des déplacements des fantômes.
- la fonction de **récompense** à chaque itération est définie comme la différence de score entre l'itération courante et l'itération précédente.
- l'ensemble des **états** : les états doivent être définis de sorte à être markoviens, i.e. chaque état doit contenir toutes les informations nécessaire à la prise de décision à l'instant t.

Tous les éléments du MDP sauf les états sont déjà définis. La classe `EtatPacmanMDPClassic` du package `pacman.environnementRL` implémente l'interface `Etat`, et sert à définir les états du MDP dans le cas du jeu Pacman. Le constructeur prend en paramètre d'entrée un état du jeu Pacman.

Si on utilise directement un état du jeu Pacman (`StateGamePacman`) comme un état du MDP, l'ensemble des états sera trop grand. De plus, certaines informations dans l'état du jeu Pacman ne sont pas indispensables pour la décision de l'agent. Il faut donc extraire de l'état du jeu Pacman à chaque instant, les éléments nécessaires à la prise de décision.

1. Complétez la classe `EtatPacmanMDPClassic` du package `pacman.environnementRL`. Celle-ci doit permettre d'instancier à partir d'un état du jeu pacman à un instant donné, l'état du MDP correspondant.

   Vous devrez en particulier redéfinir la méthode `hashCode()` , car ces états seront des clefs de la `HashMap` utilisées dans la classe `QLearningAgent`.
2. Testez votre agent en exécutant la classe `testRLPacman` du package `simuProjetPacman`. Vous pouvez modifier différents paramètres dans cette classe, comme le labyrinthe utilisé, le nombre de parties d'apprentissage, le nombre de parties de test (politique gloutonne), l'affichage du jeu pour les parties de test, ...
3. Vérifiez que l'apprentissage fonctionne correctement en regardant la courbe d'apprentissage (qui trace la somme des récompenses reçues par épisode) et les statistiques sur le pourcentage de parties gagnées en phase de test (politique gloutonne).
4. Testez avec d'autres environnements pour voir les limites de l'approche tabulaire dans ce contexte.

4. Seules les actions qui n'emmènent pas dans un mur sont considérées.

2.3 Q-Learning et généralisation pour le jeu Pacman

Dans cette partie, l'objectif est d'améliorer les capacités de généralisation entre états du Q-Learning, en utilisant une fonction d'approximation pour approximer la fonction Q (cf. Annexe 3).

La fonction Q est approximée comme une combinaison linéaire de *features* ou fonctions caractéristiques ϕ_i :

$$\begin{aligned} Q_\theta(s,a) &= \sum_{i=1}^{M} \phi_i(s,a)\theta_i \\ &= \theta_1\phi_1(s,a) + \theta_2\phi_2(s,a) + ... \end{aligned} \tag{1}$$

avec $\theta_i \in \Re$ les poids, $\phi_i : S \times A \to \Re$ les fonctions caractéristiques.

Les *features* sont *choisies* (dans ce TP vous devrez les définir) mais les poids sont appris de sorte à avoir la meilleure approximation de la fonction Q. Ainsi, à chaque étape (s, a, s', r), les poids sont mis à jour selon :

$$\theta_k \leftarrow \theta_k + \alpha(r + \gamma \max_b Q(s', b) - Q(s,a))\phi_k(s,a) \tag{2}$$

L'interface *FeatureFunction* est commune à tout vecteur de fonctions caractéristiques. Elle permet de récupérer le nombre de *features* ainsi que le vecteur de *features* pour un couple (s, a).

1. Tout d'abord, compléter la classe `QLApproxAgent` du package `agent.rlapproxagent` pour avoir un agent apprenant par Q-Learning, avec une combinaison linéaire de *features* pour approximer la fonction Q. Le constructeur prend en paramètre un vecteur de *features* composé d'un ensemble de ϕ_i.

   Remarque : Vous ne devez plus utiliser la table Q, donc assurez-vous que les méthodes de la classe mère `QLearningAgent` que vous appelez dans la classe `QLApproxAgent` ne dépendent pas de la table Q.
2. Ensuite, compléter la classe `FeatureFunctionIdentity` qui renvoie un vecteur de *features* simple. Ce vecteur a une taille égale au nombre de couples (s, a) et est composé uniquement de 0 et d'un seul 1. Pour chaque élément (s, a), on a un seul 1 positionné au même endroit.
3. Compléter la classe `EtatPacmanMDPClassic` du package `pacman.environnementRL` en lui ajoutant une méthode `int getDimensions()` qui renvoie le nombre total d'états. Cette méthode est nécessaire au constructeur de la classe `FeatureFunctionIdentity`.
4. Avec ces *features*, l'agent `QLApproxAgent` devrait fonctionner de manière identique au `PacmanQAgent`. Testez votre `QLApproxAgent` en exécutant la classe `testRLPacman` du package `simuProjetPacman` (**vous devez modifier la méthode `setRLAgent` pour instancier le bon agent**).

Une fonction caractéristique capture une ou plusieurs propriétés importante d'un état. Dans le cas du pacman, on pourra par exemple utiliser les fonctions caractéristiques suivantes :

- $\phi_0(s,a) = 1\ \forall s \in S, a \in A$ est le biais
- $\phi_1(s,a)$ est le nombre de fantômes qui peuvent atteindre en un pas la position future du pacman (position atteinte par le pacman lorsqu'il fait a dans s)
- $\phi_2(s,a)$ est la présence d'un pac-dot à la position future du pacman (position atteinte par le pacman lorsqu'il fait a dans s)
- $dist(s,a)$ est la distance au plus proche pac-dot depuis la position future du pacman (position atteinte par le pacman lorsqu'il fait a dans s).

$$\phi_3(s,a) = \frac{dist(s,a)}{mapsize}$$

1. Compléter la classe `FeatureFunctionPacman` qui renvoie un vecteur de *features* pour le jeu du Pacman.
2. Testez votre `QLApproxAgent` en exécutant la classe `testRLPacman` du package `simuProjetPacman` (**vous devez modifier la méthode `setRLAgent` pour instancier le bon agent**).

3 Annexe : Apprentissage par renforcement et généralisation avec fonctions d'approximation linéaires

L'objectif est d'être capable de généraliser les valeurs apprises dans les états rencontrés à de nouvelles situations inconnues.

Dans le cas d'un espace d'état de grande dimension, on est confronté au problème appelé **curse of dimensionality** : la quantité de données d'entrainement nécessaires pour un bon apprentissage (couverture de l'espace d'état) augmente de manière exponentielle avec la dimension de l'espace d'état. Les conséquences sont un coût élevé pour obtenir des données (notamment dans le cas de l'apprentissage supervisé où les données d'entrainement doivent être labellisées), une augmentation du temps de calcul et des besoins en mémoire.

En apprentissage par renforcement, contrairement à la plupart des méthodes d'apprentissage automatique, l'agent apprenant peut « créer » ses propres données d'entrées par l'intermédiaire de ses interactions avec l'environnement. Cependant, avec de grands espaces d'états et d'actions, l'agent doit réaliser un très grand nombre d'expériences pour collecter assez de données.

Une approche classique pour résoudre ce problème est l'utilisation de *features* ou **fonctions caractéristiques**. Une feature contient une information spécifique sur les données. Toutes les features sont réunies dans un **vecteur de features** qui a une dimension plus faible que les données elles-mêmes. L'algorithme d'apprentissage prend alors en entrée ce vecteur de features et apprend la pondération de ces features.

Le choix des features pour une tâche spécifique peut se faire de manière experte (comme dans le TP Pacman). On peut aussi apprendre les features en utilisant les réseaux de neurones.

3.1 Q-Learning avec approximation linéaire et vecteur de caractéristiques

3.1.1 Notations

La fonction Q est approximée comme une combinaison linéaire de *features*/fonctions caractéristiques ϕ_i :

$$\begin{aligned} Q_\theta(s,a) &= \sum_{i=1}^{M} \phi_i(s,a)\theta_i \\ &= \theta_1\phi_1(s,a) + \theta_2\phi_2(s,a) + ... \\ &= \boldsymbol{\phi}(s,a)^T\boldsymbol{\theta} \end{aligned} \tag{3}$$

avec $\boldsymbol{\phi}$ un vecteur de features qui a pour éléments des fonctions caractéristiques $\phi_i(s,a)$: $S \times A \to \mathbb{R}$ et $\boldsymbol{\theta}$ un vecteur de poids de même taille que le vecteur de features.

Un fonction caractéristique doit renvoyer des valeurs similaires pour des paires d'état-action similaires.

NOTE : On utilise généralement comme premier élément dans le vecteur de features une fonction caractéristique $\phi_1 = 1$ qui est le biais.

3.1.2 Fonctions caractéristiques expertes, apprentissage des poids

L'objectif est d'apprendre les poids $\theta_i \in \mathbb{R}$ pour obtenir une bonne approximation de la fonction Q. A chaque échantillon (s, a, s', r),

— la prédiction est $\hat{y} = Q_\theta(s,a) = \sum_i \theta_i\phi_i(s,a)$ ($\hat{y}$ dépend de $\boldsymbol{\theta}$)

— la valeur cible est $y = r + \gamma max_b Q_\theta(s',b)$ (y dépend de $\boldsymbol{\theta}$)

La valeur cible est estimée par amorçage : on utilise l'estimation des états successeurs pour estimer l'état courant.

Cela revient à trouver $\boldsymbol{\theta}$ qui minimise une fonction de l'erreur entre la prédiction et la valeur cible sur échantillon de k exemples :

$$argmin_\theta E(\boldsymbol{\theta}) \texttt{avec} E(\boldsymbol{\theta}) = 1/2 \sum_k (y_k - \hat{y}_k)^2$$

Pour cela, on applique une méthode par descente de gradient qui permet de trouver le minimum d'une fonction.

— la descente de gradient est appliquée à une fonction $E(\boldsymbol{\theta})$ dont on cherche le minimum :

$$E(\boldsymbol{\theta}) = 1/2(y - \sum_i \theta_i \phi_i(s,a))^2 = 1/2(y - \theta_1\phi_1(s,a) - ... - \theta_m\phi_m(s,a))^2$$

— à partir de $\boldsymbol{\theta}$ on suit le vecteur donné par le gradient de la fonction E en $(\boldsymbol{\theta})$:

$$\vec{\bigtriangledown} E(\boldsymbol{\theta}) = (\frac{\partial E(\theta_1, ..., \theta_m)}{\partial \theta_1}, ... \frac{\partial E(\theta_1, ..., \theta_m)}{\partial \theta_k}, ...)^T$$

— le calcul du gradient donne :

$$\frac{\partial E(\boldsymbol{\theta})}{\partial \theta_k} = (y - \sum_i \theta_i \phi_i(s,a))(\frac{\partial (y - \sum_i \theta_i \phi_i(s,a))}{\partial \theta_k}) = (y - \sum_i \theta_i \phi_i(s,a))(-\phi_k(s,a))$$

$$\vec{\bigtriangledown} E(\boldsymbol{\theta}) = -(y - \sum_i \theta_i \phi_i(s,a))\boldsymbol{\phi}$$

— la mise à jour du vecteur de poids à chaque pas selon (s, a, s', r) est alors :

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \alpha \vec{\bigtriangledown} E(\boldsymbol{\theta_t}) \tag{4}$$

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t + \alpha(y - \sum_i \theta_i \phi_i(s,a))\boldsymbol{\phi} \tag{5}$$

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t + \alpha(r + \gamma \max_b Q_{\theta_t}(s', b) - Q_{\theta_t}(s,a))\boldsymbol{\phi}(s,a) \tag{6}$$

— cela revient à mettre à jour chaque poids k à chaque pas selon (s, a, s', r) :

$$\theta_k \leftarrow \theta_k - \alpha \frac{\partial E(\boldsymbol{\theta})}{\partial \theta_k}$$
$$\theta_k \leftarrow \theta_k + \alpha(y - \hat{y})\phi_k(s,a)$$
$$\theta_k \leftarrow \theta_k + \alpha(r + \gamma \max_b Q(s', b) - Q(s,a))\phi_k(s,a)$$

4 Annexes

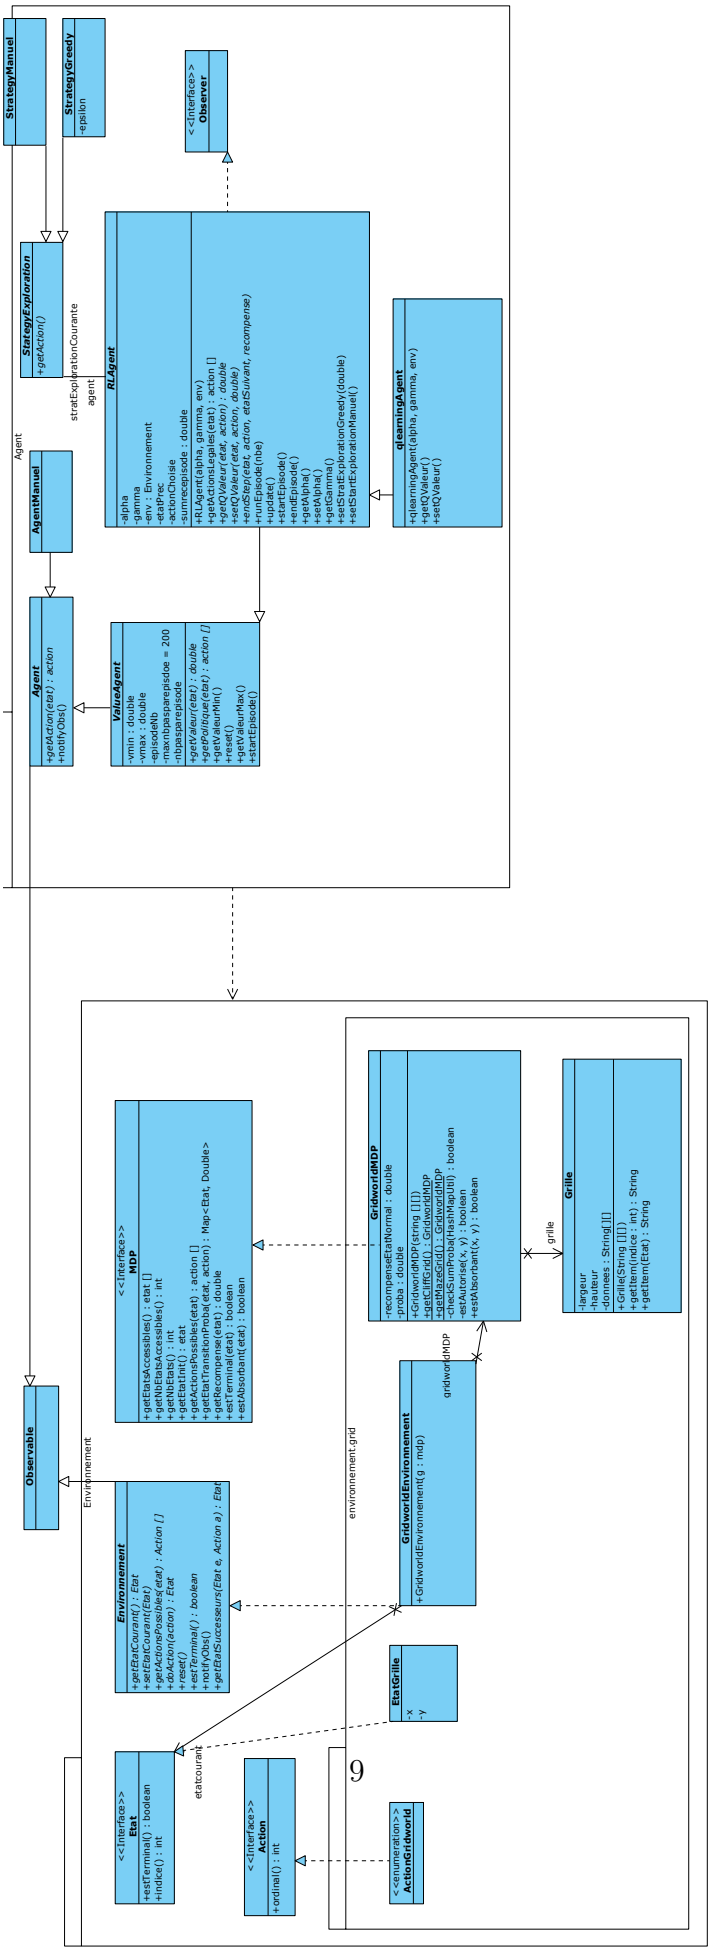
StrategyManuel
StrategyGreedy
-epsilon
<<Interface>>
Observer
StrategyExploration
+getAction()
stratExplorationCourante
agent
RLAgent
-alpha
-gamma
-env : Environnement
-etatPrec
-actionChoisie
-sumrecepisode : double
+RLAgent(alpha, gamma, env)
+getActionsLegales(etat) : action []
+getQValeur(etat, action) : double
+setQValeur(etat, action, double)
+endStep(etat, action, etatSuivant, recompense)
+runEpisode(nbe)
+update()
+startEpisode()
+endEpisode()
+setAlpha()
+getAlpha()
+getGamma()
+setStratExplorationGreedy(double)
+setStartExplorationManuel()
qlearningAgent
+qlearningAgent(alpha, gamma, env)
+getQValeur()
+setQValeur()
Agent
AgentManuel
Agent
+getAction(etat) : action
+notifyObs()
ValueAgent
-vmin : double
-vmax : double
-episodeNb
-maxnbpasparepisdoe = 200
-nbpasparepisode
+getValeur(etat) : double
+getPolitique(etat) : action []
+getValeurMin()
+reset()
+getValeurMax()
+startEpisode()
<<Interface>>
MDP
+getEtatsAccessibles() : etat []
+getNbEtatsAccessibles() : int
+getNbEtats() : int
+getEtatInit() : etat
+getActionsPossibles(etat) : action []
+getEtatTransitions(etat, action) : Map<Etat, Double>
+getRecompense(etat) : double
+estTerminal(etat) : boolean
+estAbsorbant(etat) : boolean
GridworldMDP
-recompenseEtatNormal : double
-proba : double
+GridworldMDP(string [][])
+getCliffGrid() : GridworldMDP
+getMazeGrid() : GridworldMDP
-checkSumProba(HashMap<Integer, Double> map)
-estAutorise(x, y) : boolean
+estAbsorbant(x, y) : boolean
grille
Grille
-largeur
-hauteur
-donnees : String[][]
+Grille(String [][])
+getItem(indice : int) : String
+getItem(Etat) : String
Observable
Environnement
environnement.grid
Environnement
+getEtatCourant() : Etat
+setEtatCourant(Etat)
+getActionsPossibles(etat) : Action []
+doAction(action) : Etat
+reset()
+estTerminal() : boolean
+notifyObs()
+getEtatSuccesseurs(Etat e, Action a) : Etat
GridworldEnvironnement
+GridworldEnvironnement(g : mdp)
gridworldMDP
EtatGrille
-x
-y
etatcourant
<<Interface>>
Etat
+estTerminal() : boolean
+indice() : int
<<Interface>>
Action
+ordinal() : int
<<enumeration>>
ActionGridworld